



INSTITUTO SUPERIOR  
POLITÉCNICO CÓRDOBA

Tecnicatura:

## TECNICATURA SUPERIOR EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL



### I CUATRIMESTRE - EVIDENCIA N° 2

**MÓDULO: Práctica Profesionalizante II, Desarrollo de  
Sistemas de IA, Aprendizaje Automático.**

**PROFESORA:** Sol Figueroa

#### INTEGRANTES:

|                    |            |
|--------------------|------------|
| Direni Carlos      | 28.117.281 |
| Testa Andrea Paola | 25.442.630 |
| García Carlos      | 40.518.523 |
| Moreno Raúl        | 29.201.107 |

**GITHUB:** <https://github.com/Cdireni/PracticaProf2-ISPC.git>

**COLAB:** Minería de Datos\_EvII.ipynb

## Presentación del Proyecto

Desde el equipo **VisioNet**, hemos seleccionado el proyecto desarrollado en el módulo de Minería de Datos para ser implementado como eje central de nuestra Práctica Profesionalizante.

Este proyecto consiste en el desarrollo del S.I.M.A. (Sistema Inteligente de Monitoreo Ambiental), una solución analítica e integral diseñada específicamente para la Escuela ProA de Río Tercero. A través de la aplicación de técnicas de ciencia de datos y análisis de variables climáticas, el sistema tiene como objetivo monitorear el entorno ambiental para optimizar procesos, generar alertas frente a anomalías y fundamentar la toma de decisiones dentro de la institución educativa.

## 1. Comprensión del negocio o problema

### 1.1 Definición clara del problema a resolver:

El proyecto se enmarca en la necesidad de diseñar, construir y poner en funcionamiento una Estación Meteorológica en la ciudad de Río Tercero, provincia de Córdoba. El objetivo físico es recolectar datos climáticos locales a través de sensores propios. Actualmente, el equipo de proyecto no cuenta con datos históricos de esta ciudad específica, pero dispone de un dataset representativo con mediciones climáticas de otras localidades clave del país (incluyendo Córdoba Capital, Rosario y Buenos Aires). Este conjunto de datos servirá como base de conocimiento previo para la toma de decisiones técnicas vitales para la factible construcción de la estación.

Al instalar nuevos sensores en Río Tercero, nuestro equipo necesita parámetros de referencia para saber si las lecturas iniciales son correctas y cómo se comportan las variables climáticas en la región centro. Por lo tanto, el problema predictivo y de análisis se define con la siguiente pregunta: ¿Cómo podemos utilizar los datos históricos de ciudades cercanas y con comportamiento climático similar (como Córdoba Capital) para construir un modelo predictivo que estime la Temperatura Máxima esperada en función de otras variables (como la Humedad Relativa y la Velocidad del Viento), y así establecer una línea base de referencia que permita validar y calibrar los nuevos sensores en Río Tercero?

## 1.2 . Contexto organizacional o aplicación

Actualmente, la Estación Meteorológica genera un flujo constante de mediciones; sin embargo, la ausencia de una infraestructura de procesamiento transforma este potencial en un "lago de datos crudos" (data swamp). Al no existir una etapa de limpieza, integración y almacenamiento estructurado, los datos se acumulan sin sentido pedagógico ni utilidad práctica. Esta desconexión impide que la institución aproveche la oportunidad de generar información estratégica y predictiva, dejando a los estudiantes sin una herramienta real para experimentar con el ciclo de vida del dato.

Realizar la toma de decisiones vitales para la "factible construcción de la Estación Meteorológica" utilizando un conjunto de datos climáticos de Argentina y en particular de las provincias de la Región Centro.

## 1.3 Objetivos del proyecto

- Predecir la temperatura máxima en función de la humedad y la ciudad para optimizar el diseño de la estación.
- Analizar los patrones climáticos de la zona centro (Córdoba, Rosario, Buenos Aires) para entender la correlación entre variables, como el impacto de la humedad en las temperaturas
- Desarrollar y entrenar un modelo de Machine Learning de regresión para predicción de valor de temperatura.
- Generar conocimiento útil que brinde recomendaciones técnicas basadas en datos empíricos para el despliegue de la estación en Río Tercero

## 1.4 Identificación de indicadores de éxito (KPIs)

- Nivel de Error del Modelo: Lograr un modelo de regresión con un margen de error bajo (evaluado mediante métricas como el Error Cuadrático Medio - MSE o el Error Absoluto Medio - MAE), lo que garantizará que las predicciones usadas como referencia para Río Tercero sean confiables.
- Identificación de Patrones Regionales: Documentar al menos dos relaciones claras entre variables (por ejemplo, la correlación alta del 0.83 detectada entre Temperatura Máxima y Mínima) que sirvan como regla de validación de calidad para los datos que empiecen a arrojar los futuros sensores de Río Tercero.

## 2. Comprensión de los datos

### 2.1. Descripción de las fuentes de datos:

El dataset utilizado es temperature data arg 2023.csv, un conjunto de datos climáticos de Argentina correspondiente al año 2023, cargado desde Google Drive mediante su identificador de archivo público. El dataset crudo contiene 1.916 registros distribuidos en 7 columnas:

- **Fecha:** fecha de la medición (con distintos formatos: DD/MM/YYYY y YYYY-MM-DD).
- **City:** ciudad de origen (16 ciudades únicas en el dataset original, incluyendo Tucumán como la más frecuente con 355 registros).
- **Max Temperature:** temperatura máxima diaria en °C.
- **Min Temperature:** temperatura mínima diaria en °C.
- **Precipitación:** precipitaciones en mm (eliminada en etapa de preparación).
- **Wind Speed:** velocidad del viento en km/h.
- **Relative Humidity:** humedad relativa en %.

El resumen estadístico inicial del dataset crudo arrojó los siguientes valores para las variables numéricas:

| Estadístico | Tiempo. Máx. (°C) | Temp. Mín. (°C) | Vel. Viento (km/h) | Hum. Relativa (%) | Obs.             |
|-------------|-------------------|-----------------|--------------------|-------------------|------------------|
| count       | 1.191             | 1.191           | 1.191              | 1.191             | Dataset limpio   |
| mean        | 17,60             | 10,10           | 24,97              | 59,63             | Promedio general |
| min         | 2,00              | -3,00           | 10,00              | 30,00             | Valor mínimo     |
| 25%         | 12,00             | 6,00            | 17,80              | 44,50             | Percentil 25     |
| 50%         | 17,00             | 10,00           | 24,90              | 59,00             | Mediana          |
| 75%         | 23,00             | 15,00           | 32,30              | 74,80             | Percentil 75     |
| max         | 36,00             | 22,00           | 40,00              | 90,00             | Valor máximo     |
| std         | 7,99              | 6,49            | 8,56               | 17,38             | Desv. estándar   |

**Nota:** estos valores corresponden a los 1.763 registros con datos numéricos completos en el dataset original, antes de la limpieza..

Visualizamos la distribución de la Temperatura Máxima con un histograma de degradado térmico y una curva de tendencia (KDE).

### **Análisis exploratorio (EDA): Valores nulos y registros incompletos**

Para abordar la presencia de registros nulos o inconsistentes en el conjunto de datos inicial, se implementó una estrategia de limpieza estructurada. En primera instancia, se procedió a la eliminación total de la columna *Precipitation* debido a su baja relevancia estructural para los objetivos de predicción térmica.

Posteriormente, se realizó una verificación técnica de celdas vacías; la aplicación de métodos de descarte permitió omitir aquellas filas que presentaban valores faltantes en las variables críticas, garantizando la integridad del flujo de datos para el entrenamiento del modelo.

### **Detección y tratamiento de outliers (valores atípicos)**

Con el fin de evitar sesgos en el análisis predictivo, se combinaron técnicas estadísticas y visuales para la gestión de anomalías:

- Se aplicó el método del Rango Intercuartílico (IQR) para la identificación numérica de extremos, detectando 14 valores atípicos en *Max Temperature* y 11 en *Min Temperature*.
- Desde una perspectiva visual, se utilizó el diagrama de caja (Boxplot) como herramienta fundamental para validar la distribución y evidenciar la dispersión de estas lecturas fuera de los límites esperados.
- En la etapa de tratamiento, se imputaron como nulos los registros físicamente imposibles, estableciendo umbrales técnicos de coherencia climática (máximas superiores a 50°C o mínimas inferiores a -20°C).

### **3. Preparación de los datos: Limpieza y transformación**

Para homogeneizar la información y asegurar su utilidad práctica, se ejecutaron los siguientes procesos de transformación:

- **Limpieza categórica:** Se estandarizó la columna *City* mediante un diccionario de correcciones que subsanó errores tipográficos y variantes de escritura (como "Bs As" o "Buenos Aires"), centrando el análisis exclusivamente en las ciudades de la Región Centro seleccionadas.
- **Casting y normalización de formatos:** Las variables numéricas registradas como texto fueron saneadas (reemplazo de comas por puntos) y convertidas a tipo *float64*. Asimismo, se unificaron los diversos formatos de la columna *Date* al estándar *datetime*.
- Finalmente, se realizó una depuración de espacios en blanco en los encabezados de las columnas para asegurar una arquitectura de datos prolija y funcional.

#### 4. Construcción del dataset final

**Consolidación del subconjunto definitivo:** Tras la ejecución de la limpieza categórica, el casting técnico de variables y la imputación de anomalías como nulos, se procedió a la exportación del *df\_final*. Esta operación aseguró la integridad estructural mediante una eliminación absoluta de registros incompletos, garantizando un flujo de datos prolijo para las fases de modelado.

- Se aplicó una copia profunda del dataframe acompañada del método de descarte de nulos para fijar la arquitectura final del corpus.
- Como instancia previa de validación de calidad, se cuantificó y auditó la presencia de registros duplicados en el conjunto de datos.

#### 5. Análisis bivariado y multivariado

**Interacciones y cruces de variables:** El estudio de dependencias atmosféricas se abordó desde dos niveles analíticos para desentrañar el comportamiento de las variables climáticas:

- **Nivel Bivariado:** La meta estadística se orientó a identificar correlaciones directas entre variables independientes y dependientes, evaluando, por ejemplo, la relación matemática entre la humedad y los niveles de precipitación.
- **Nivel Multivariado:** El análisis se centró en la segmentación geográfica, analizando cómo fluctúan las temperaturas climáticas cruzadas frente a las cinco geografías principales seleccionadas para el estudio.

### 3. Visualizaciones e interpretación de resultados

**3.1 Interpretación del impacto del EDA:** Las representaciones gráficas permitieron extraer conclusiones estratégicas sobre la naturaleza del dato y la calidad de la información:

#### Comprensión de datos: Analisis Univariado


##### Gráfico 1 - Distribución de Temperatura Máxima con Degradado Térmico

Este gráfico inaugura el EDA post-limpieza con un análisis univariado de la variable más relevante del dataset.

##### Gráfico 1 · Distribución de Temperatura Máxima con Degradado Térmico

**Tipo:** Histograma con 30 bins + curva KDE superpuesta — Análisis Univariado

**Variables:** Max Temperature (°C) — variable única, dataset completo (5 ciudades, año 2023)



El histograma utiliza un degradado de color coolwarm (azul frío a rojo caliente) para colorear cada barra según su posición en el eje X, logrando que la codificación visual refuerce el contenido semántico (temperaturas bajas = azul, altas = rojo). La curva KDE (Kernel Density Estimation) verde se superpone para mostrar la tendencia continua de la distribución. Con 30 bins se logra

suficiente resolución para detectar modas sin sobreajustar el ruido. El eje Y representa densidad de probabilidad (density=True), haciendo comparables las alturas entre bins de diferente amplitud.

**Insight CRISP-DM:** La distribución agrega todas las ciudades y estaciones. La probable presencia de dos crestas (bimodalidad) refleja que el dataset mezcla climas contrastantes: Tucuman subtropical vs. Mendoza continental, y registros de verano vs. invierno. Esto justifica la segmentación por ciudad y estación en los análisis bivariados posteriores. La curva KDE permite detectar esta multimodalidad con mayor claridad que el histograma solo.

**Limitación:** Al agregar cinco ciudades con climas distintos, la distribución combinada puede ocultar patrones importantes. Para un análisis más riguroso, se recomiendan histogramas separados por ciudad o violín plots comparativos.

### Análisis Bivariado: Humedad vs. Temperatura por Estación

Los gráficos 2 a 9 componen el núcleo del análisis bivariado. Todos utilizan complot de Seaborn, que combina nube de dispersión con regresión lineal simple e intervalo de confianza, facetado por ciudad (columna) y/o coloreado por otra variable (hue).

El dataset se restringe a la zona centro: Córdoba, Buenos Aires y Rosario. Las variables eje son siempre Humedad Relativa (%) en X y Temperatura Máxima (°C) en Y.


### Gráficos 2 a 5 - Tendencias estacionales por ciudad (4 gráficos, uno por estación)

**Gráfico 2-5 · Tendencias en Verano / Otoño / Invierno / Primavera — Córdoba, Buenos Aires y Rosario**


**Tipo:** complot facetado (col=City, hue=City) — Análisis Bivariado Estacional

**Variables:** X: Relative Humidity (%) | Y: Max Temperature (°C) | Columna: Cordoba / Buenos Aires / Rosario


**Tendencias en Verano (Enero - Marzo)  
Cordoba, Buenos Aires y Rosario**




**Tendencias en Otoño (Marzo - Junio)  
Cordoba, Buenos Aires y Rosario**



**Tendencias en Invierno (Junio - Septiembre)  
Cordoba, Buenos Aires y Rosario**






## Gráficos 6 a 9 - Tendencia lineal por mes dentro de cada estación

### Gráfico 6-9 · Tendencia Lineal por Mes — Verano / Otoño / Invierno / Primavera

**Tipo:** complot facetado (col=City, hue=Month) — Análisis Bivariado Mensual


**Variables:** X: Relative Humidity (%) | Y: Max Temperature (°C) | Color: Mes (dentro de la estación) | Columna: Cordoba / Buenos Aires / Rosario



Marzo con líneas de distinta inclinación. Esto permite ver la evolución intraestacional de la relación Humedad/Temperatura. El hallazgo principal registrado en el notebook: en Enero la relación era muy fuerte (línea muy inclinada), pero en Marzo la temperatura fue más estable frente a la humedad (línea mas plana). En Diciembre se incluyen los 31 días como Primavera para evitar un grafico extra.

**Insight CRISP-DM:** La subestructura mensual confirma que la estacionalidad no es homogénea dentro de cada estación. Para el modelo predictivo de la estación meteorológica, incluir el mes como variable (o su codificación cíclica seno/coseno para preservar la continuidad enero-diciembre) mejorará significativamente la performance frente a usar solo la humedad. Esta granularidad mensual es especialmente crítica en las estaciones de transición (otoño y primavera).

Gráfico 10 - Análisis Explicativo de Tendencias Térmicas por Localidad (año completo)



**Insight CRISP-DM:** La comparación de las pendientes anuales permite identificar qué ciudad responde más a la humedad como predictor de temperatura. Rosario, por su posición continental sin efecto marítimo, suele mostrar mayor variabilidad (nube más dispersa, menor R<sup>2</sup>). Buenos Aires exhibe la relación más estable gracias al efecto regulador del Río de la Plata. Si se entrena un modelo único para las tres ciudades, la ciudad debe ser variable categórica para capturar estas diferencias sistemáticas.


## Análisis Multivariado: Distribución y Correlaciones

### Gráfico 11 - Boxplot: Distribución de Temperaturas Máximas por Ciudad

**Gráfico 11 · Distribución de Temperaturas Máximas por Ciudad — Análisis Multivariado**

**Tipo:** Boxplot (x=City, y=Max Temperature) — paleta Viridis — Análisis Multivariado

**Variables:** X: City (5 ciudades) | Y: Max Temperature (°C)



El boxplot compara simultáneamente la distribución de temperatura máxima entre las cinco ciudades del dataset. Cada caja muestra: línea central = mediana, cuerpo = rango intercuartílico Q1-Q3 (50% central de los datos), bigotes = hasta 1.5 x IQR, y puntos individuales = outliers remanentes post-limpieza. La paleta Viridis codifica cada ciudad con un color de azul a amarillo, añadiendo una dimensión visual adicional. Los outliers que permanecen son climáticamente válidos (olas de calor, frentes polares) ya que la limpieza solo elimina valores físicamente imposibles ( $>50^{\circ}\text{C}$  o  $<-20^{\circ}\text{C}$ ). Se espera observar: Tucuman con la mediana mas alta (clima subtropical); Mendoza con la mayor amplitud de caja (clima árido continental, grandes diferencias

verano/invierno); Buenos Aires y Rosario con medianas similares pero distinta dispersión; Córdoba en posición intermedia.


**Insight CRISP-DM:** Las diferencias en medianas y dispersiones entre ciudades confirman que City debe incluirse como variable categórica en cualquier modelo predictivo. Un modelo que ignore la ciudad subestima consistentemente la temperatura de Tucuman y sobreestima la de Mendoza en invierno. La comparación de las amplitudes de las cajas también revela que Mendoza es la ciudad más difícil de predecir (mayor variabilidad anual), lo que impacta en el MSE esperado del modelo.

## Gráfico 12 - Heatmap: Matriz de Correlación (S.I.M.A.)

### Gráfico 12 · Matriz de Correlación (S.I.M.A.)

**Tipo:** Heatmap de correlación de Pearson — anotaciones numéricas — paleta cool warm — Análisis Multivariado

**Variables:** Max Temperature | Min Temperature | Wind Speed | Relative Humidity



El heatmap muestra la matriz de correlación de Pearson entre las cuatro variables numéricas del dataset. Cada celda muestra el coeficiente  $r$  en escala de -1 a +1: rojo intenso = correlación positiva fuerte, azul intenso = negativa fuerte, blanco/neutro = sin correlación lineal. La diagonal

principal siempre vale 1.0 (variable consigo misma). Las anotaciones numéricas en negrita con formato .2f permiten leer el valor exacto sin ambigüedad. Los parámetros de estilo (linewidths=1.5, square=True, bar kws) mejoran la legibilidad. Correlaciones esperadas: Max Temp <-> Min Temp: alto positivo (0.80-0.90) — ambas variables suben y bajan juntas estacionalmente. Max Temp <-> Humidity: negativo moderado (aprox. -0.40 a -0.60) — confirma el análisis bivariado. Wind Speed <-> Temp: correlación baja o nula.

**Insight CRISP-DM:** La correlación alta entre Max Temp y Min Temp indica colinealidad potencial. Si ambas se usan como features en un modelo de regresión, conviene calcular el VIF (Variance Inflation Factor) para evaluar si es necesario eliminar una. La correlación Humedad/Temperatura confirma que la humedad mejora la predicción de temperatura, pero no la explica completamente ( $r^2$ ), coherente con los complots que muestran dispersión real.


**Limitación:** Pearson mide únicamente la relación lineal. Si existe una relación cuadrática (U invertida) entre viento y temperatura, puede ser  $\sim 0$  aunque la relación sea real. Se recomienda complementar con el coeficiente de Spearman y matrices de scatter (pair lot) para detectar relaciones no lineales antes de la fase de modelado.

### Gráfico 13 - Relación Humedad/Temperatura en Córdoba por Estación

#### Gráfico 13 · Relación Humedad/Temperatura en Córdoba por Estación

**Tipo:** complot (col=Season, hue=Season, solo Cordoba) — paleta Viridis

**Variables:** X: Relative Humidity (%) | Y: Max Temperature (°C) | Columna: Otoño / Invierno / Primavera / Verano



Este gráfico es el único que fija una sola ciudad (Córdoba) y varía la estación como faceta. A diferencia de los gráficos 2-5 que comparan ciudades dentro de una estación, aquí se observa como cambia la relación Humedad/Temperatura a lo largo del año para la misma localidad. La ciudad de Córdoba fue seleccionada por ser referencia de la zona centro y por su relevancia para el proyecto de estación meteorológica. Las estaciones se ordenan lógicamente: Otoño, Invierno, Primavera, Verano. La paleta Viridis asigna un color distinto a cada estación, facilitando la identificación visual de los paneles.

**Insight CRISP-DM:** Este es el gráfico más informativo para el objetivo de construir una estación meteorológica en la zona centro. Muestra que la relación Humedad -> Temperatura en Córdoba tiene pendiente distinta según la estación: negativa y pronunciada en verano, casi plana en invierno. Para el modelo predictivo esto implica la necesidad de un término de interacción Humedad x Estación, o bien modelos separados por estación. Esta es la evidencia más directa para justificar una arquitectura de modelado estacional.

### 3.2. Selección de variables relevantes

**Criterios de selección y decisiones técnicas:** Con el propósito de consolidar la arquitectura analítica del Sistema Inteligente de Monitoreo Ambiental (S.I.M.A.), se establecieron parámetros técnicos para la depuración y conservación de las variables críticas del estudio:

- Tras la exploración profunda del conjunto de datos, se seleccionaron como variables métricas fundamentales para el entrenamiento del modelo: **Max Temperature** (Temperatura Máxima), **Min Temperature** (Temperatura Mínima), **Wind Speed** (Velocidad del Viento) y **Relative Humidity** (Humedad Relativa).
- En contraposición, se determinó el descarte absoluto de la variable **Precipitation** debido a su baja relevancia estructural, procediendo a su eliminación técnica del corpus mediante la función *drop*.
- Se conservaron **Date** (Fecha) y **City** (Ciudad) como los ejes categóricos de contexto indispensables para la segmentación temporal y geográfica.
- Finalmente, el tratamiento de la variable **City** se abordó de forma estratégica, implementando un filtro técnico para restringir el análisis exclusivamente a 3 ciudades clave de interés: Rosario, Córdoba y Buenos Aires.